

Matriz de Optimización de Costos

Sistema de Notificación de Vencimientos de FSC — justificación de modelo por tarea

Precios de referencia (API de Anthropic, tarifa estándar vigente): Claude Sonnet 5, USD 2 / USD 10 por millón de tokens de entrada / salida. Claude Haiku 4.5, USD 1 / USD 5 por millón de tokens. El Batch API reduce estos valores un 50% adicional para procesamiento no urgente.

1. Tareas del sistema y modelo asignado

Tarea	¿Usa IA?	Modelo	Justificación
Cálculo de días restantes y ventana de aviso	No	— (Code / JavaScript)	Es aritmética de fechas determinística. Usar un LLM para esto sería costo puro sin ningún beneficio de razonamiento — un antipatrón de "IA decorativa". Costo: USD 0.
Redacción de mail + asignación de prioridad (Rama A)	Sí	Claude Sonnet 5	Tarea de generación de texto corto con algo de razonamiento (cruza criticidad, días restantes e historial para decidir tono y prioridad). Sonnet 5 ofrece la mejor relación costo/calidad para esta complejidad media.
Extracción de datos desde texto libre + confirmación (Rama B)	Sí	Claude Sonnet 5	Es la tarea de mayor exigencia de comprensión del sistema: interpretar lenguaje natural ambiguo ("seguimos esperando novedades") y no confundirlo con una confirmación real. Se prioriza precisión sobre costo, dado que un falso positivo aquí escribiría una fecha de vencimiento incorrecta.

2. Alternativas evaluadas y descartadas

Alternativa	Por qué se descartó para este proyecto
Claude Haiku 4.5 para redacción y extracción	Es el modelo recomendado para clasificación y extracción de alto volumen. Se descartó para esta entrega porque el volumen actual es bajo (unos pocos certificados por corrida) y la diferencia de costo entre Haiku y Sonnet, a este volumen, es de centavos — no justifica el riesgo de perder precisión en la interpretación de texto ambiguo. Se documenta como la primera optimización a aplicar si el volumen escala (ver sección 3).
Claude Opus	Sobredimensionado para las dos tareas del sistema (redacción corta y extracción estructurada). El costo (USD 5 / USD 25 por MTok) no se justifica frente a la ganancia de calidad, que es marginal para este tipo de tarea.
Batch API para el cron diario	El Batch API (50% más barato) es ideal para procesamiento masivo sin restricción de latencia. No se usó en esta entrega porque el HITL requiere que el mail de aprobación llegue en tiempo real dentro de la misma ejecución; el modelo de espera del Batch API (hasta 24 h de demora) es incompatible con ese requisito. Sí se recomienda para una futura tarea de pre-cálculo masivo de prioridades, desacoplada del HITL.

3. Proyección de costo y ahorro estimado

Estimación conservadora de tokens por ejecución (un certificado, un ciclo de IA):

Escenario	Tokens entrada (aprox.)	Tokens salida (aprox.)	Costo por llamada (Sonnet 5)	Costo por llamada (Haiku 4.5)
Redacción de aviso (Rama A)	~350	~180	USD 0.0025	USD 0.0013
Extracción de datos (Rama B)	~400	~60	USD 0.0014	USD 0.0007

A este volumen (bajas decenas de certificados activos), el costo mensual de IA del sistema completo es inferior a USD 1, independientemente del modelo elegido — razón por la cual la decisión de usar Sonnet

5 en ambas tareas prioriza precisión sobre ahorro marginal.

El ahorro real y relevante aparece si el volumen escala a producción (cientos de certificados, múltiples empresas clientes). En ese escenario:

- Migrar la redacción de avisos (Rama A) a Haiku 4.5 recortaría ese costo a la mitad, sin pérdida de calidad perceptible en una tarea de generación de texto corto y estructurado.
- Procesar el cálculo de prioridades de todos los certificados en un job nocturno vía Batch API sumaría un 50% adicional de ahorro sobre esa porción del costo.
- Mantener Sonnet 5 exclusivamente en la extracción de la Rama B (la tarea que exige mayor precisión de lectura) conserva la calidad donde más importa, mientras se abarata todo lo demás.

Combinando ambas medidas, la proyección de ahorro sobre el costo de IA total del sistema, a escala, es de aproximadamente 60–70%, sin modificar la arquitectura del flujo ni los puntos de control humano.